新疆大学本科毕业论文(设计)

论文题目:	基于深度学习的行人重识别系统设计与实现
学生姓名:	齐开放
学　　号:	20201302217
所属院系:	计算机科学与技术学院
专　　业:	计算机科学与技术
班　　级:	计算机 20-1
指导老师:	李莉
日　　期:	2024 年 4 月 26 日

声　明

本人郑重声明，本论文是在导师的指导下独立完成，除加注和致谢外，文中不包含他人所发表或撰写的成果。本人拥有自主知识产权，没有抄袭、剽窃他人成果，对于参考的文献已经加注并表示感谢。若有不实之处，本人愿意承担相关法律责任。

作者签名：齐开放

签字日期：2024 年 4 月 26 日

本科学位论文（设计）版权使用授权书

本人完全了解学校有关保留、使用本科学位论文（设计）的规定，同意学校保留并向国家有关部门或机构送交论文（设计）的复印件和电子版，允许论文（设计）被查阅和借阅。本人授权新疆大学将本学位论文（设计）的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文（设计）。

本学位论文（设计）属于：

保　密☐，在__年解密后适用本授权书。

不保密☑。

作者签名：齐开放　　指导教师签名：李莉

日期：2024 年 4 月 26 日　　日 期：2024 年 4 月 26 日

摘 要

行人重识别技术是指在不同摄像头角度下的视频或者图像中检索目标人员。在当前我国安保能力不断增强以及“天网”工程不断推进的情况下，生活中的摄像头数量急剧增加，并且摄像头所拍摄的视频已经作为我国安保系统的重要信息来源，行人重识别技术在安保领域中的地位也愈加重要。

本文介绍了一个基于深度学习的行人重识别系统的设计与实现，主要包括行人检测模块、行人重识别模块以及系统的设计与实现，通过行人检测模块检测视频或者图片中的行人，再通过行人重识别模块判断检测出的行人是否为检测目标，从而实现整个系统的行人重识别功能。

在行人检测模块中，本文使用的是基于 YOLOv8 的行人检测模型，YOLOv8 是 YOLO 系列算法的第八代算法，YOLOv8 相对于前几代 YOLO 系列算法拥有更快的训练速度和更优异的性能，并且参数量和计算量较少，适合对视频的实时检测。本文在设计行人检测模型时，在基于 YOLOv8n 的网络框架上通过添加通道注意力机制，实现对模型的改进。

在行人重识别模块中，本文的行人重识别网络以 ResNet50 作为主体框架，采用 PCBNet 的思想，对特征图进行分割，增加特征图的颗粒度信息，并且对提取到的特征向量采用 Id Loss 和 TriHard Loss 作为协同损失函数进行训练。

在系统设计上，本文采用 PyQt5 以及 QFluent 进行整体系统设计，并且提供对于用户相对友好的 UI 界面。

关 键 词：行人重识别技术；YOLOv8；通道注意力机制；PCBNet；TriHard Loss

ABSTRACT

Person re-identification technology refers to the retrieval of target individuals in videos or images from different cameras. With the continuous enhancement of China's security capabilities and the advancement of the "Skynet" project, the number of cameras used in daily life has sharply increased, and the videos captured by cameras have become an important source of information for China's security system. Person re-identification technology is also becoming increasingly important in the field of security.

This paper introduces the design and implementation of a people re-identification system based on deep learning, which mainly includes a pedestrian detection module, a people re-identification module, and the design and implementation of the system. The pedestrian detection module detects pedestrians in videos or images, and then determines whether the detected pedestrian is the detection target through the people re-identification module, thereby achieving the people re-identification function of the entire system.

In the pedestrian detection module, this paper uses a pedestrian detection model based on YOLOv8, which is the eighth generation algorithm of the YOLO series. YOLOv8 has a faster training speed and better performance compared to previous generations of YOLO series algorithms, and has fewer parameters and computational complexity, making it suitable for real-time video detection. This paper improves the pedestrian detection model by adding channel attention mechanism on the YOLOv8n based network framework.

In the people re-identification module, the people re-identification network of this paper uses ResNet50 as the main framework and adopts the PCBNet concept to segment the feature maps, increase the granularity information of the feature maps, and train the extracted feature vectors using Id Loss and TriHard Loss as collaborative loss functions.

In terms of system design, this paper adopts PyQt5 and QFluent for overall system design, and provides a relatively user-friendly UI interface.

KEY WORDS: Re-identification; YOLOv8; Channel attention; Trihard loss

目 录

1 绪论 1
1.1 选题背景及意义 1
1.2 国内外研究现状 1
1.3 本文主要工作 2
1.4 章节安排 2
2 行人检测算法设计 4
2.1 引言 4
2.2 基于 YOLOv8n 改进的行人检测网络 4
2.2.1 Cycle GAN[21] 4
2.2.2 SENet 6
2.2.3 YOLOv8 7
2.2.4 基于 YOLOv8n 改进的行人检测网络 9
2.3 实验结果 10
2.3.1 实验环境 10
2.3.2 数据集 11
2.3.3 评价指标 11
2.3.4 消融实验 11
2.3.5 实验结果 12
2.4 本章小结 13
3 行人重识别算法设计 14
3.1 引言 14
3.2 基于 PCBNet 的行人重识别网络 14
3.2.1 ResNet 14
3.2.3 PCBNet 15
3.2.4 TriHard Loss 16
3.2.5 基于 PCBNet 的行人重识别网络 17
3.3 实验结果 18
3.3.1 实验环境 18
3.3.2 数据集 18
3.3.4 评价指标 18
3.3.4 消融实验 19
3.3.5 实验结果 20
3.4 本章小结 20

4 行人重识别系统的设计与实现.....21
4.1 引言.....21
4.2 需求分析.....21
4.2.1 功能性需求分析.....21
4.2.2 非功能性需求分析.....21
4.3 系统开发环境.....22
4.4 系统功能综述.....22
4.4.1 用户层.....23
4.4.2 业务层.....24
4.4.3 数据层.....24
4.5 系统效果展示.....24
4.6 本章小结.....26
5 总结与展望.....27
5.1 总结.....27
5.2 展望.....27
参考文献.....29
致　谢.....32

1 绪论

1.1 选题背景及意义

随着我国安防事业的不断完备以及我国人民对于安防的意识不断提升，人民安全也越来越受到国家和政府的重视。因此，为了保障人民的安全以及对于违法犯罪事件证据的获取，国家和政府也在不断提高公共场合的摄像头数量，近些年在农村也可以明显看到摄像头的普及。摄像头数量的增加，大大提高了我国安防在监控和预防犯罪等方面的能力[1]。

行人重识别技术则是通过要检索的特定行人照片，实现在不同摄像头拍摄的照片或者视频下，对该目标人物的识别。该技术可以极好地通过摄像头实现对嫌疑人的搜索，帮助工作人员处理事件，提高效率，也可大大减少对案件的投入成本[2]。

1.2 国内外研究现状

近年来，深度学习不断出现在大众的眼前，深度学习以其优异的学习能力在各个领域都有很好的效果，推进了各个领域的进步，其在行人重识别领域，也取得了一定的效果。

基于深度学习的行人重识别其主要方法就是通过深度学习进行特征提取，得到一个特征向量，通过特征向量将图片进行差异化，然后进行判断[3]。目前主流的基于深度学习的行人重识别模型都是通过有监督学习进行训练的，这种方式通常识别率较高，但是需要耗费极大的人工成本去给各种数据打标签。由于有监督学习的大量成本，弱监督学习也在近些年被提出，弱监督学习只需要少量的数据标签即可进行训练，但是这种方式通常识别率较低[4]。跨模态也在近期被提出，它不同于平常的数据，它采用的不是在可见光下的图像，而是一些其他模态的图像，如由红外摄像机捕捉到的数据[5]。

在有监督学习中，主要有表征学习和度量学习两种方法[6]。表征学习的主要思想是通过一些网络进行图像的特征提取，通过有效的特征提取，以达到较好的图像之间差异的量化，在图像分类领域中，通常在训练阶段中通过图像分类来获

取损失进而进行网络训练，以达到一个较好的特征提取，最后输出特征层的数据。

度量学习的主要思想则是对提取的特征进行量化，表征学习主要体现在特征提取上，度量学习则主要体现在损失函数上，通过损失函数实现对相似图像的特征向量在高维空间中距离更近，不同的图像距离更远，从而达到一个区分的目的。目前主要的度量学习的损失函数有对比损失，分类损失，三元组损失等[7]。

1.3 本文主要工作

本文主要研究了行人检测技术与行人重识别技术以及两种技术在实际场景中的应用。基于当前行人检测和行人重识别技术的研究和发展，本文提供了一种基于 YOLOv8 的改进行人检测模型以及一种基于 PCBNet[8]思想改进的行人重识别模型，实现了精确、有效的行人检测和行人重识别功能，为实际生活场景的应用提供了方案。本文具体工作如下：

（1）本文设计了一种基于 YOLOv8n[9]算法的改进行人检测网络模型。采用了在 YOLOv8n 结构中通过添加通道注意力机制[10]实现了对 YOLOv8n 网络模型的优化，使得网络能够更好地学习不同通道之间的重要程度，提高了模型对于行人特征的提取能力。在参数量和计算量基本不变的情况，实现了模型性能的小幅度提升。

（2）本文提供了一种基于 PCBNet 的改进行人重识别模型。在网络模型设计上，使用 ResNet50[11]提取图像特征，基于 PCBNet 的思想，将特征图分为六个部分进行计算，使用 TriHard Loss[12]和 Id Loss 作为协同损失函数。

（3）基于上述对行人检测技术和行人重识别技术的研究，本文设计了一个能够适用实际场景的行人重识别系统。该系统具备多项功能，能够为用户提供行人检测功能和行人重识别功能，并且支持图片和视频流。经过系统测试，该系统具有良好的鲁棒性和适应性，能够较好地适应于实际情况。

1.4 章节安排

本文主要分为五个章节，下面将简单介绍各个章节的安排与内容：

第一章为绪论。该章首先介绍了选题的背景及意义，然后对国内外行人重识别研究现状进行了探讨。之后又详细介绍了本文的内容和结构，保证了整篇文章内容清晰、结构完整。

第二章为行人检测算法设计。设计了一种基于 YOLOv8n 改进的行人检测模型，通过在网络中添加通道注意力机制，提高了网络对于不同通道重要程度的学习能力，进而实现了模型性能的提升。

第三章为行人重识别算法设计。设计了一种基于 PCBNet 改进的行人重识别模型。通过在 PCBNet 中添加 TriHard Loss 和 Id Loss，增强了模型对于行人特征向量的提取能力，提高了模型的识别性能。

第四章为行人重识别系统的设计与实现。该章节对系统设计进行了功能性需求分析、非功能性需求分析，并且也介绍了系统设计的具体细节，包括系统的整体框架设计以及部分系统 UI 界面的设计，对系统进行了效果展示。

第五章为总结与展望。对全文总体进行总结，并且对未来的行人重识别技术发展方向进行了展望。

2 行人检测算法设计

2.1 引言

行人检测是目标检测的一个重要分支，主要作用是预测出图像中的行人位置。在各种交通监控、自动驾驶等相关行业具有重要地位[13]。常用的方法包括基于人工特征的传统方法和基于深度学习的现代方法。

基于人工特征的传统方法通常使用滑动窗口和分类器相结合的方式进行预测，但是这种方法进行行人检测时，需要大量计算窗口中是否含有行人，模型复杂并且计算量较高，在复杂的场景中往往表现较差。

本文的行人检测模型则是基于 YOLOv8 算法进行设计。YOLO 系列算法[14-20]凭借着低计算量、高性能的优势在行人检测算法领域中占据着重要地位。YOLOv8 相对于之前的 YOLO 系列算法，拥有更快的拟合速度、更高的准确度并且计算量低，非常适合作为实时目标检测模型。

2.2 基于 YOLOv8n 改进的行人检测网络

2.2.1 Cycle GAN[21]

（1）算法介绍

Cycle GAN 也称为循环生成对抗网络，是在 GAN（Generative Adversarial Networks）的基础上发展而来。GAN 是一种通过训练数据来生成虚拟数据的一种模型，Cycle GAN 则可以实现图像在两种不同风格之间的转换，比如把夏季照片转换为冬季照片，并且在训练数据集上不需要成对的数据就能够实现模型的训练，在数据准备上会简单很多，非常具有应用前景。

（2）模型结构

Cycle GAN 主要包括两个判断器 Dx 和 Dy，两个生成器 G 和 F，输入数据的 x 经过 G 可以生成虚拟数据 G(x)，F 可通过输入数据 y 生成 F(y)。Dx 主要接收 x 和 F(y)来判别输入数据是否为真实数据，Dy 同理。模型简要结构如图 2-1 所示：

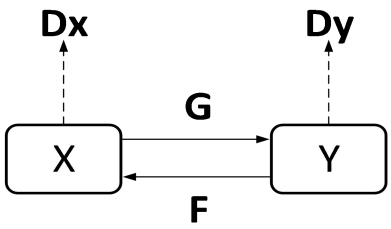

图 2-1 Cycle GAN 简要结构

以 X->Y 举例，模型接受 X 的输入 x，一方面进入 Dx 进行判别，另一方面通过 G 生成 G(x)，将生成的 G(x)进入 Dy 进行判别，再进入 F 生成 F(G(x))。Y->X 与该流程类似。模型详细训练流程如图 2-2 所示：

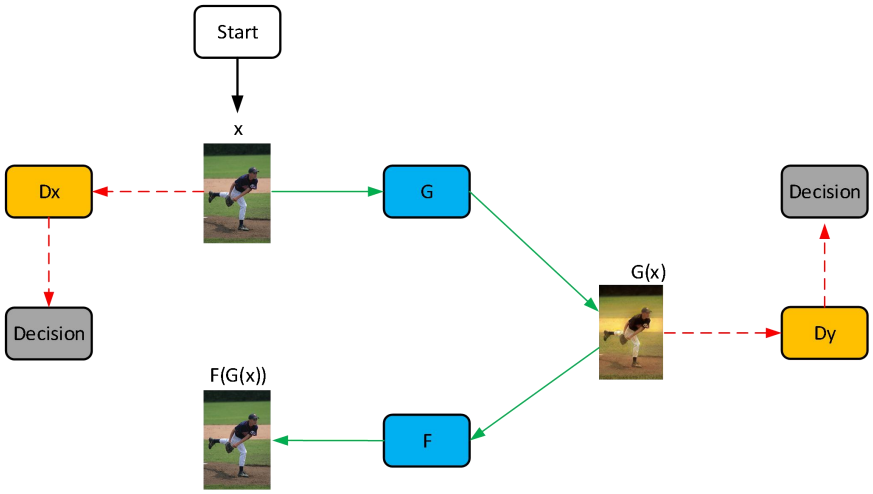

图 2-2 （a）Cycle GAN X->Y 训练流程

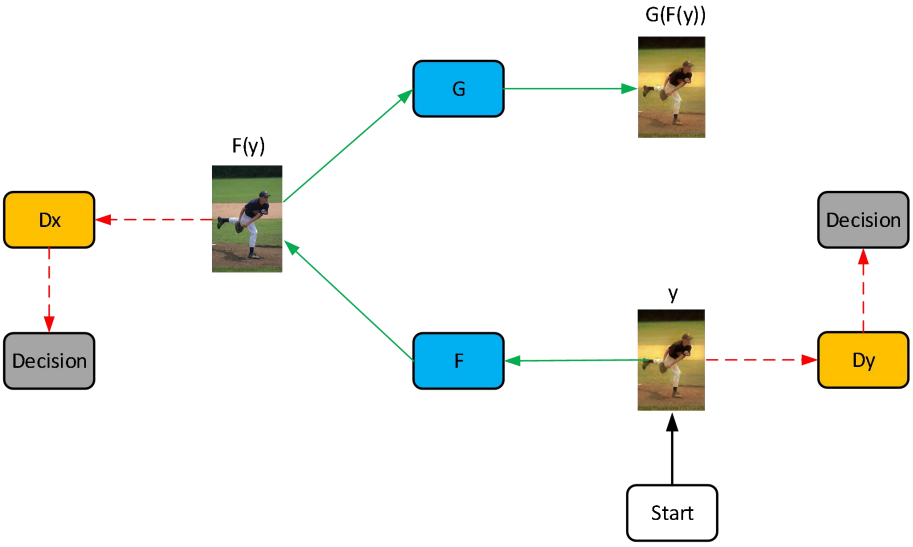

图 2-2 （b）Cycle GAN Y->X 训练流程

在损失函数设计上，Dx 和 Dy 的目的是能够准确判断出输入数据是真实数据还是虚拟数据，G 和 F 的目的则是能够生成 Dx 和 Dy 无法判断真假的数据，为了实现生成器和判断器相互对抗的过程，因此 Cycle GAN 设计了一种名为对抗

损失的损失函数L_{GAN}，在训练过程中，共有两个对抗损失函数，分别为 X->Y 过程的对抗损失$L^{x\to y}{}_{GAN}(F,D_X,Y,X)$和 Y->X 过程的对抗损失$L^{y\to x}{}_{GAN}(G,D_Y,X,Y)$，对抗损失函数公式分别如下：

$$L^{x\to y}{}_{GAN}(F,D_X,Y,X)=E_{x\sim p_{data}(x)}[\log(D_X(x))]+E_{y\sim p_{data}(y)}[1-\log(D_X(F(y))] \quad (2\text{-}1)$$

$$L^{y\to x}{}_{GAN}(G,D_Y,X,Y)=E_{y\sim p_{data}(y)}[\log(D_Y(y))]+E_{x\sim p_{data}(x)}[1-\log(D_Y(G(x))] \quad (2\text{-}2)$$

以 X->Y 的对抗损失函数进行举例，当 Dx 越准确，也就是 Dx(x)越接近于 1 时，损失函数左半部分越小，有利于 Dx 参数的更新，当 F(y)越接近于 X 数据的分布时，损失函数右半部分越小，有利于 F 参数的更新，因此，整体来说，该损失函数实现了判断器和生成器相互对抗相互成长的功能。

但是为了避免两个生成器生成的样本相互矛盾，简单来说就是避免生成器生成样本时不学习输入数据的特征而是直接生成符合目标样本分布的数据，导致生成的数据跟输入数据没关系，因此又引入了循环一致损失：

$$L_{\text{cyc}}(G,F)=E_{x\sim p_{data}(x)}[\|F(G(x))-x\|_1]+E_{y\sim p_{data}(y)}[\|F=G(F(y))-y\|_1] \quad (2\text{-}3)$$

对循环一致损失进行分析，当 F(G(x))与 x 越接近时，损失函数左半部分越小，当 G(F(y))与 y 越接近时，损失函数右半部分越小，整体来说，该损失函数实现了生成器根据输入数据的特征进行生成数据，而不是直接生成符合目标数据特征的数据。因此，最后整个流程的训练损失函数为对抗损失函数和循环一致损失之和：

$$L_{GAN}(\mathrm{G},F,D_X,D_Y)=E_{x\sim p_{data}(x)}[\log(D_X(x))]+E_{y\sim p_{data}(y)}[1-\log(D_X(F(y))] \quad (2\text{-}4)$$

2.2.2 SENet

（1）算法介绍

SENet 的主要思想就是建立特征通道之间的相互依赖关系。简单来说就是给每个特征通道一个权重，让网络自己去学习每个特征通道的重要程度，从而提高模型的提取特征的能力，增强模型性能。

（2）模型结构

SENet 的实现方式是在获得原本网络的某一层的输出后，假设上一层的网络输出数据形状为 C*H*W，在 SENet 中会先经过自适应池化层得到长度为 C 的特征向量，然后再经过两层线性层，两层线性层的输入输出形状为（C，C/Ratio），

（C/Ratio，C），Ratio 默认为 4，目的是降低计算量，增加模型推导速度。当经过两层线性层之后，再进行 softmax 处理从而得到对于输入数据的所有特征通道的权重，最后将该权重与输入数据的对应特征通道数据进行相乘，SENet 的模型结构如图 2-3 所示：

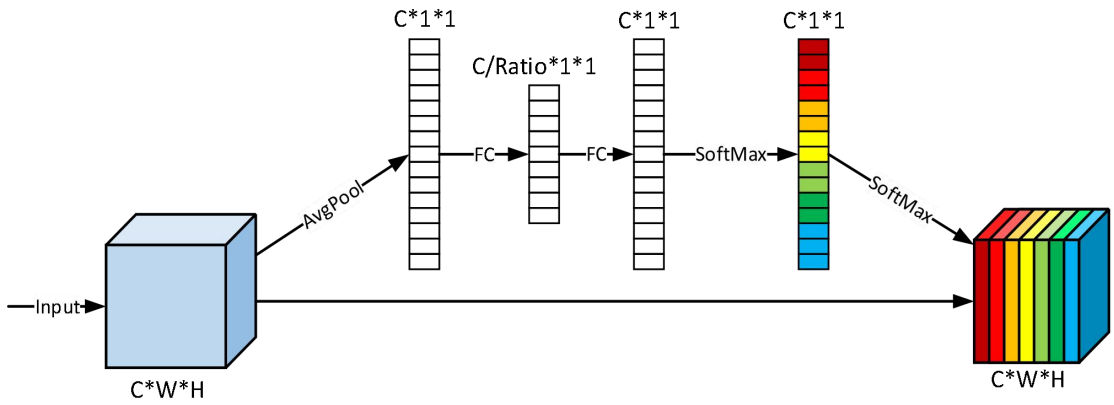

图 2-3 通道注意力机制详细结构

2.2.3 YOLOv8

（1）算法介绍

YOLOv8 在历代 YOLO 算法的基础上，通过添加新的功能和创新点，提升了模型的性能和灵活性。其创新点主要包括一个新的骨干网络，一个新的 Anchor Free 检测头，以及一个新的损失函数。使得 YOLOv8 拥有更快的拟合速度以及更好的性能。YOLOv8 共提供了五种网络模型，其模型大小、参数量、计算量以及性能各不相同，供用户自己挑选和使用，YOLOv8 各模型数据来自 YOLOv8 官网。YOLOv8 个系列模型参数如表 2-1 所示：

YOLOv8 大概可以分为三个模块，分别为提取特征的 Backbone 模块，进行多尺度融合的 Neck 模块，进行预测的 Head 模块。

在 Backbone 模块上，YOLOv8 借鉴了 CSPNet[22]的思想，跟 YOLOv5 不同的是，YOLOv8 将 YOLOv5 中的 C3 模块更改为了 C2f 模块，进一步实现了模型的轻量化，继续沿用了 YOLOv5 中的 SPPF[23]模块，在 Neck 模块中则是继续沿用了 PAN[24]的思想。

Head 部分相对 YOLOv5 改动较大，采用了当前主流的解耦头结构，将分类和检测头分离，同时将 Anchor-Base 改为了 Anchor-Free。

在实际训练中采用 BCE Loss 作为分类损失，采用 DFL Loss + CIOU 作为回归损失。

表 2-1　YOLOv8 系列模型

网络	图像大小	mAP50	mAP50-95	Params(M)	FLOPS(B)
YOLOv8n	640×640	53.0	37.3	3.2	8.7
YOLOv8s	640×640	61.8	44.9	11.2	28.6
YOLOv8m	640×640	67.3	50.2	25.9	78.9
YOLOv8l	640×640	69.6	52.8	43.7	165.2
YOLOv8x	640×640	70.8	53.8	68.2	257.8

（2）模型结构

由于 YOLOv8 模型整体较大，这里以 YOLOv8n 为例进行简单介绍，若要详细了解请查看 YOLOv8 官网。

YOLOv8n 网络结构如图 2-4 所示：

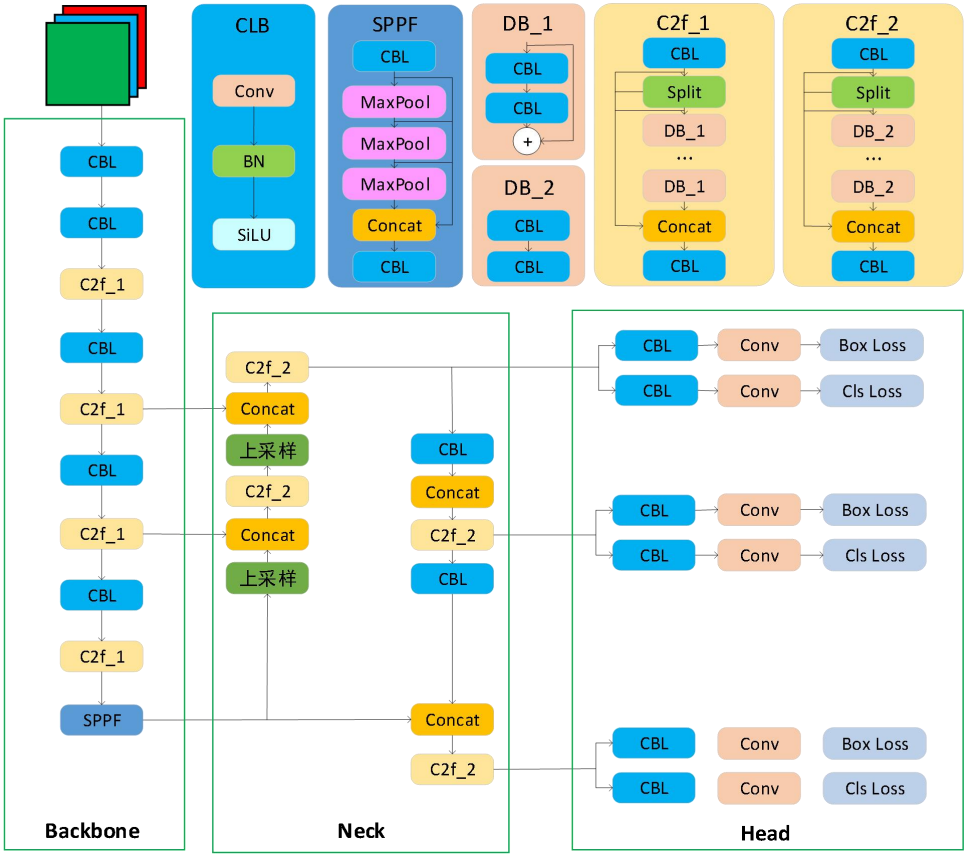

图 2-4 YOLOv8n 网络结构

在 Backbone 部分：模型接受原始图片输入，经过一些卷积模块，C2f 模块，SPPF 模块等，最后输出三种不同尺度的特征图作为 Neck 的输入。

在 Neck 部分：Neck 接受来自 Backbone 输入的三种不同尺度的特征图，然

后不断地将下层特征图进行上采样并与上一层的特征图进行 Concat，之后再经过 C2f 模块，整体经过上采样以及 C2f 模块后，上层特征图则再与下一层特征图 Concat 并且输入进 C2f 模块，最后将得到的三个不同尺度的特征图输入到 Head 模块。

在 Head 部分：Head 将分类损失与边界框损失单独计算，当得到来自 Neck 的三层特征图后，将特征图输入到两个卷积模块中，然后再分别输入到一层卷积层更改通道数，最后将得到的两个结果分别计算边框损失和分类损失。

2.2.4 基于 YOLOv8n 改进的行人检测网络

（1）模型设计

在本文中的行人检测模型设计上，采用了在基于 YOLOv8n 作为行人检测基础网络。为了提高特征图之间各通道属性之间的关联性，比如说让网络更加关注人体的头发颜色以及皮肤颜色等，因此本文在 YOLOv8n 的基础上通过在 Backbone 和 Head 中添加通道注意力机制来实现加强各通道属性之间的关联性。

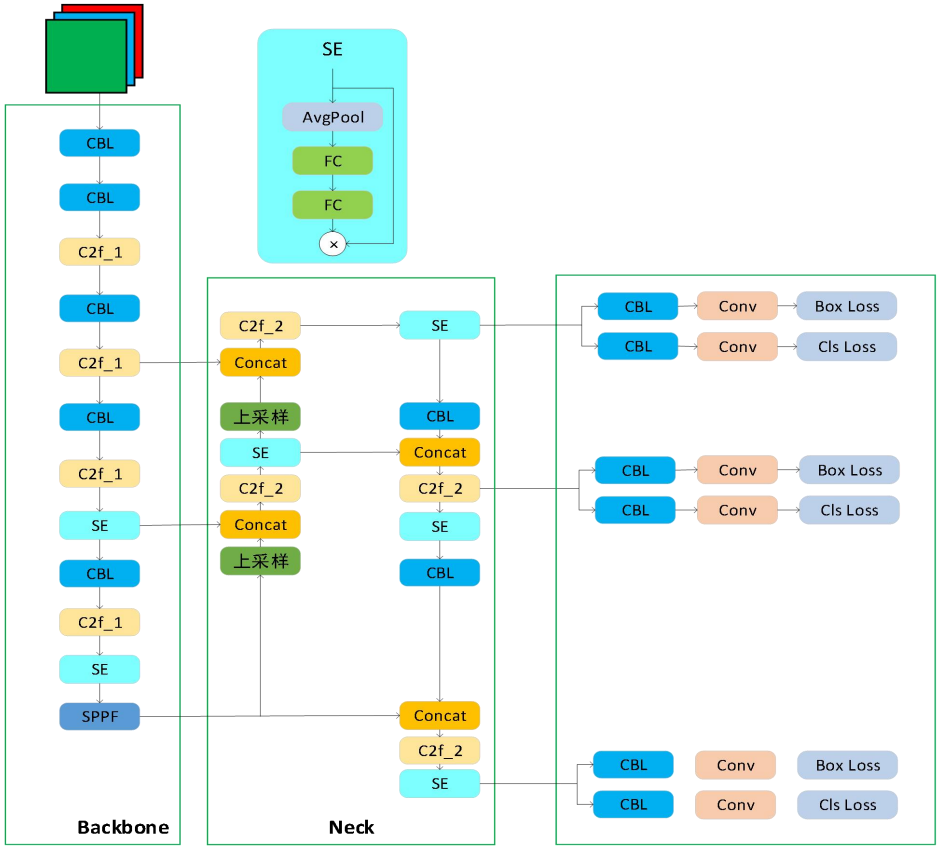

图 2-5 改进后的 YOLOv8n 网络结构

简单来讲，通道注意力机制能够加强网络对某些共享的特征通道的重视程度，使网络能够好的去处理不同通道属性之间的管理，从而提高网络的性能。更改后的 YOLOv8n 网络结构如图 2-5 所示：

（2）模型结构

本文的行人检测模型主要是在 YOLOv8n 的 Backbone 和 Head 中的 C2f 模块后添加了通道注意力机制，因为 C2f 模块具有较高的提取特征的能力，并且在模型结构开始阶段因为通道数不多的情况下通道注意力机制并不能起到太大作用，因此本文选择在 Backbone 中的后两个 C2f 模块和 Head 中的四个 C2f 模块后添加通道注意力机制。更改后的 YOLOv8n 网络结构如图 2-5 所示。

2.3 实验结果

2.3.1 实验环境

实验环境的硬件环境为 Intel(R) Xeon(R) Platinum 8352V CPU、RTX 4090 GPU，操作系统为 Ubuntu20.04，编程语言为 Python3.8，深度学习框架为 Pytorch。

训练参数：Epoch 为 200，Batch Size 为 32，初始 lr 为 0.01，优化器为 SGD 优化器，在后十个轮次关闭 mosaic 数据增强。

图 2-6 （a）Cycle GAN 处理前图像

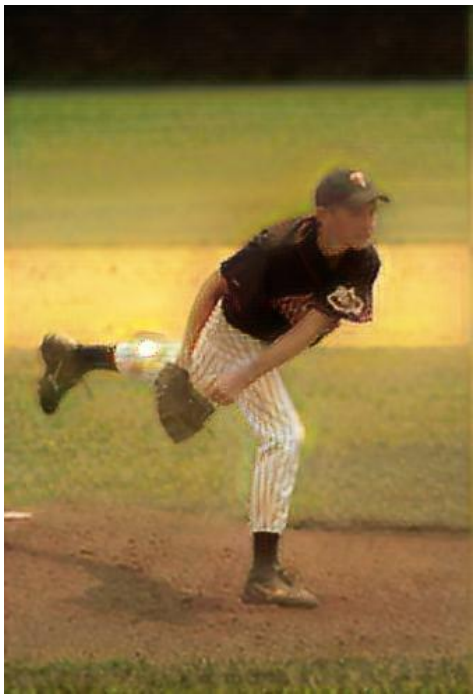

图 2-6 (b) Cycle GAN 处理后图像

2.3.2 数据集

在行人检测模型设计中，数据集采用的为 COCO 数据集[25]中含有 People 标签的部分图像作为初始数据集，之后采用 Cycle GAN 对初始数据集进行增广，生成不同色温以及分辨率的图片，以达到增强模型泛化能力的效果。最后生成的数据集总数为 5197 张，其中训练集：4197，测试集：1000。经过 Cycle GAN 生成的数据与原数据对比如图 2-6 所示。

2.3.3 评价指标

下面将介绍一些对于行人检测算法常用的一些评价指标，这些评价指标有助于了解本文中的行人检测模型的性能。行人检测模型的主要评价指标包括精确度，平均精确度等。下面将简单介绍一下这些评价指标。

（1）TP，FP，FN，TN

TP：真阴性，该位置不存在行人，也并未预测出行人

FP：假阳性，该位置不存在行人，却检测出该位置有行人。

FN：假阴性，该位置存在行人，却未检测出行人。

TP：真阳性，该位置存在行人，也检测出行人。

（2）精确度（Precision）

精确度是指所检测出的行人数中正确的数量占所有检测出的行人数量的比例。

$$precision = \frac{TP}{TP + FP} \tag{2-5}$$

（3）平均精确度（Mean Average Precision）

平均精确度（mAP）是用来计算不同类别精确度的平均值，行人检测为二分类问题，平均精确度等于精确度。在目标检测中，经常使用 mAP50 和 mAP50-95。mAP50 为置信度为 50%时的平均精确度，mAP50-95 为对不同置信度（50%-95%，步长为 5%）的 mAP 取平均。

2.3.4 消融实验

为了更好以及更加全面地去评估本文中行人重识别模型的性能，在本节中设计了消融实验，分别对 YOLOv8n 是否添加通道注意力机制进行了消融实验。在

进行消融实验中，所有模型使用的训练参数均一致。Epoch 为 200，Batch Size 为32，lr为0.01，优化器为SGD。在测试FPS时，采用的配置统一为Intel(R) Xeon(R) Platinum 8352V CPU、RTX 4090 GPU，Python-3.8.18 torch-2.1.1。消融实验结果如表 2-2 所示：

表 2-2　行人检测算法消融实验

序号	方法	mAP50	mAP50-95	Params(M)	FLOPS(B)	FPS
1	YOLOv8n	62.9	37.8	3.0	8.1	71.1
2	YOLOv8n+SENet	64.2	38.9	3.1	8.2	70.2

根据表中数据，对两种模型的性能进行评估和比较。首先在 mAP50 和 mAP50-95 方面进行考虑，YOLOv8n+SENet 取得了较好的性能，分别为 64.2% 和 38.9%，YOLOv8n 则分别为 62.9%和 37.8%，分别提升了 1.3 个百分点和 1.1 个百分点。

在参数量和计算量方面进行考虑，YOLOv8n 模型具有更少的参数量和计算量，分别为 3.0M 参数量和 8.1B 浮点运算量，YOLOv8n+SENet 则因为加入通道注意力机制造成了参数量的较低增长，分别为 3.1M 的参数量和 8.2B 的浮点运算量。

在 FPS 方面，YOLOv8n 模型获得了最高的 FPS，为 71.1 帧，并且经过对比可知，添加通道注意力机制后因为增加了少量的参数量和计算量，因此在 FPS 方面相对于未添加前有较小的降低，为 70.2 帧。

综上所述，在添加了通道注意力机制后，模型在参数量、计算量较低增长的情况下，实现了对 mAP50 以及 mAP50-95 的有效提升，并且能够保持较高的 FPS。

2.3.5 实验结果

本文在进行消融实验后，还进行了对比实验，对常用的几种行人检测模型进行比较。对比实验中使用的模型结构均为在 YOLOv8 官网上所提供，在进行对比实验中，所采用的训练参数和配置均与上节中消融实验一致。对比实验结果如表 2-3 所示：

表 2-3　行人检测算法对比实验

序号	方法	mAP50	mAP50-95	FPS
1	YOLOv3-tiny[26]	57.0	31.0	46.2
2	YOLOv5n	62.7	37.6	76.7
3	YOLOv6n	62.8	38.3	79.0
4	YOLOv8n	62.9	37.8	71.1
5	YOLOv8n+SENet	64.2	38.9	70.2

通过对比实现可得，本文所提出的行人检测方法在 mAP50 和 mAP50-95 方面具有较好的性能，相对于其他模型，至少提高了 1.3 个百分点和 0.6 个百分点，虽然在 FPS 方面欠佳，但是仍在可接受的范围内，因此，综合来说，本文提出的行人检测模型性能较好，能够满足对于视频的实时检测功能。

2.4 本章小结

本章提出了一种基于 YOLOv8n 算法改进的行人检测模型。通过在 YOLOv8n 的 Backbone 以及 Neck 部分中添加通道注意力机制，在模型参数量和计算量较低幅度的增长的情况下，有效提升了模型对于特征图不同通道重要程度的学习能力，对模型的性能起到了有效的提升。

3 行人重识别算法设计

3.1 引言

在上一章中主要对本文的行人检测模型的设计进行了介绍。在执行行人重识别功能时，通常是由行人检测模型来识别出行人的具体位置，之后根据识别出的行人位置进行剪切，将剪切后的行人图像输入到行人重识别模型，进行行人图片的特征提取和重识别。本章节将主要介绍本文的行人重识别模型设计。

3.2 基于 PCBNet 的行人重识别网络

3.2.1 ResNet

（1）算法介绍

在 ResNet 出现之前，一般情况下，随着网络层数的加深，也就意味着模型能够学习更多特征，因此模型的性能是更好的。但是当层数增加时，会出现两个问题，一个是梯度爆炸或梯度消失，梯度爆炸和梯度消失是在神经网络层数不断增加的情况下，会出现有部分数据的梯度过小或者过大难以进行计算的问题。另一个是退化问题，退化问题则是当网络层数增加到一定的程度时，出现了训练集上的精度下降，模型效果变差，其原因主要是当网络层数过深时，深层网络的参数难以进行训练，很难去拟合同等函数。梯度爆炸和梯度消失可以通过在网络中添加正则化层进行处理。直到 ResNet 提出残差的思想，退化问题才得以解决，网络才得以设置得更深。

（2）模型结构

当数据传入到残差块后，会先进行与平常网络相同的计算，通常为一些卷积层和激活函数，假设计算结果为 F(X)。残差思想则是将最后出的结果 F(X)再加上 X，最后将 F(X)+X 作为整个残差块的输出。在参数更新时，即便正常卷积层的参数无法进行更新，最差的情况也是 F(X)=0，这时候残差块的输出为 F(X)+X=X，这样就可以保证当网络层数增加时，模型的性能是不会变差的。这样也就解决了退化问题。ResNet 的残差块结构设计如图 3-1 所示：

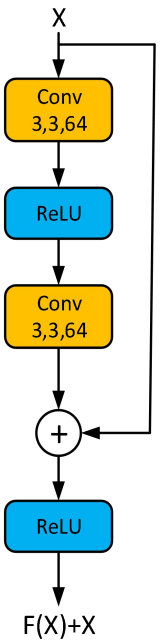

图 3-1（a）残差块结构 1

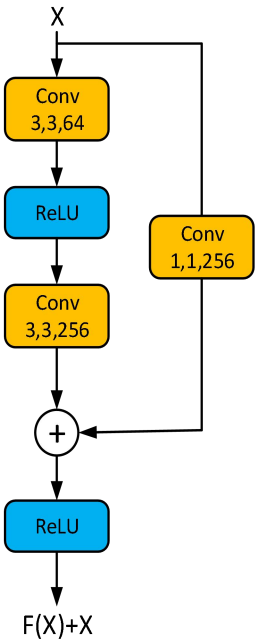

图 3-1（b）残差块结构 2

3.2.3 PCBNet

（1）算法介绍

在行人重识别中，将整张图片直接进行计算得到特征向量的方式称为全局特征方法，将一张图片分为不同部分进行计算然后得到特征向量的方式称为局部特征方法，局部特征相对于全局特征来说往往能够提供更多的细粒度信息。该网络的思想是将得到的特征图分成六份，对六份特征图分别进行处理和计算 Loss，当预测时，直接将所有的特征向量进行拼接得到最终的特征向量。整体思路简单明了，并且效果极佳。

（2）模型结构

在 PCBNet 中，使用 ResNet 得到特征图后，通过自适应全局池化层将特征图进行分割并且进行平均池化，得到六个特征向量，之后将六个特征向量经过 1x1 的卷积核降低通道数，再经过线性层处理后计算分类损失进而更新网络参数。PCBNet 结构如图 3-2 所示：

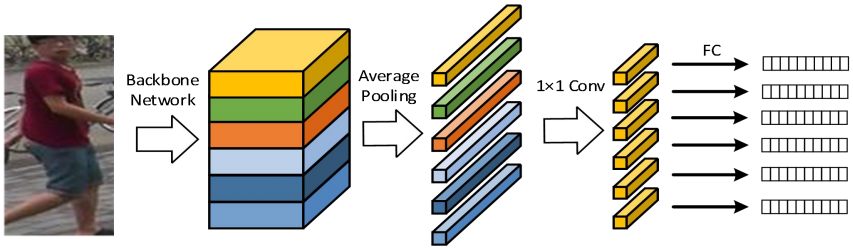

图 3-2 PCBNet 结构

3.2.4 TriHard Loss

（1）损失函数介绍

TriHard Loss 又称难样本损失，它是在三元组损失的基础上改进而得到的。两种损失函数都是度量学习中的比较经典的损失。在三元组损失函数中，同时输入三张图片，其中一张为固定图片 a，另外两张分别为正样本图片 p 和负样本图片 n，其主要思想是拉近 a 与 p 的距离，拉远 a 与 n 的距离。三元组损失可表示为：

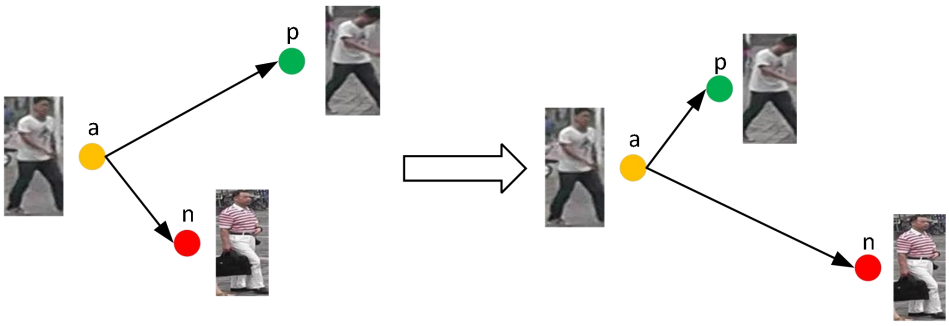

图 3-3 Triplet Loss

$$L_t = d_{a,p} + (d_{a,p} - d_{a,n} + \alpha) \tag{3-1}$$

其中 $d_{a,p}$ 为图片 a 与图片 p 的距离，$d_{a,n}$ 为图片 a 与图片 n 的距离，α 为设定的一个超参数，认为当正样本图片与负样本图片与图片 a 距离的差距大于 α 时，认为正样本与负样本已经分离开，主要损失来源于正样本内的聚合程度。

但是三元组损失中存在的问题是选取的正样本图片和负样本图片因为是随机选取，会导致差异性不足，不利于网络的训练。因此在难样本三元组损失中，对于每一个固定图片 a，会选取一个在同一个训练批次中的距离最远的正样本 p 和距离最近的负样本 a 来进行训练，增强网络的泛化能力，提高模型的性能，难样本三元组可表示为：

$$L_{th} = \frac{1}{P \times \mathrm{K}} \sum (\max_{p \in A}(d_{a,p}) - \min_{p \in B}(d_{a,n}) + \alpha) \tag{3-2}$$

在这个公式中，K 为每个行人 ID 在一个训练批次中挑的图片个数，P 为在一个训练批次中挑选的行人 ID 个数，即 batch size=P×K，其中 A 为与图片 a 具有相同 ID 的所有图片，B 则为与图片 a 具有不同行人 ID 的所有图片。

（2）具体实现

假设训练批次大小为 9，每个行人选取三张图片，因此每个训练批次就含有

3 个人。在计算损失时，会先计算出所有图片间的距离，然后分别挑选出每张图片的正样本距离最大的那张图片和负样本距离最小的那张图片，再进行三元组损失。TriHard Loss 计算过程如图 3-4 所示：

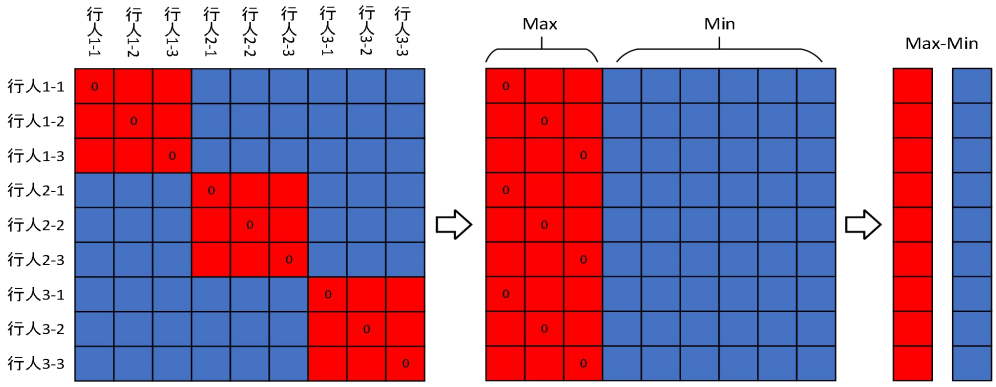

图 3-4 TriHard Loss 计算过程

3.2.5 基于 PCBNet 的行人重识别网络

（1）模型设计

在行人重识别模型设计中，采用 ResNet50 作为特征提取网络，得到特征图后，采用 PCBNet 的思想，将得到的特征图分成了六个部分进行单独计算，在模型损失函数设计上，采用 TriHard Loss 和 Id Loss 作为协同损失函数的方法，将两种损失函数相加作为模型总损失函数。

（2）模型结构

在通过将特征图分为六个部分后，分别对六个部分进行全局平均池化，得到六个特征向量，对于 TriHard Loss，会将得到的六个特征向量 Concat 为一个特征向量，然后再进行 TriHard Loss 计算，对于 Id Loss，则会将得到的六个特征向量再分别经过一层 FC 层，使得输出的特征向量长度等于行人 ID 数，之后再进行 Id Loss 的计算。改进后的行人重识别算法网络结构如图 3-5 所示：

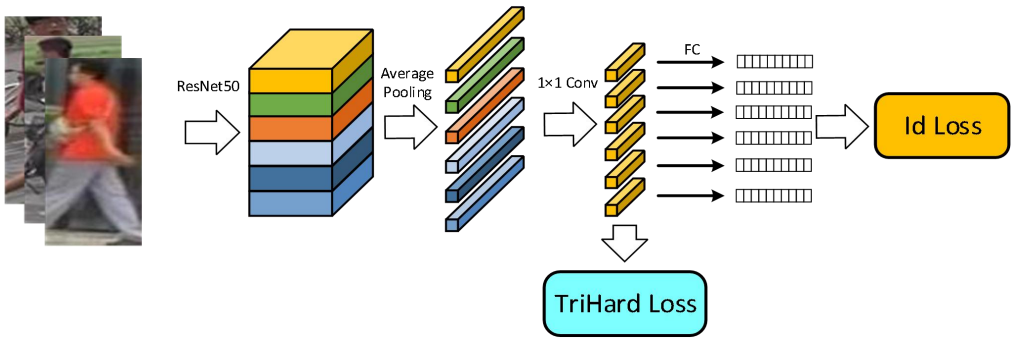

图 3-5 行人重识别算法网络结构

3.3 实验结果

3.3.1 实验环境

实验环境的硬件环境为 Intel(R) Xeon(R) Platinum 8352V CPU、RTX 4090 GPU，操作系统为 Ubuntu20.04，编程语言为 Python3.8，深度学习框架为 Pytorch。

训练参数：Epoch 为 150，Batch Size 为 64，初始 lr 为 0.01，优化器为 SGD 优化器。

3.3.2 数据集

在本文的行人重识别模型设计中采用的数据集为 Market1501 公共数据集[27]。Market1501 来自清华大学校园，采用 6 个摄像头，总共标注了 1501 个行人，其中 751 人用于训练器，750 人用于测试集，训练集和测试集不含有重复行人。在本文行人重识别模型训练中，训练集采用的是 bounding_box_train 文件夹中的图片，共 12936 张图片，测试集采用 query 中的图片，共 3368 张图片，gallery 集采用 query 目录下的图片，共 13115 张图片。

3.3.4 评价指标

下面将介绍一些关于行人重识别模型的评价指标，这些评价指标有助于了解本文中行人重识别模型的性能。行人重识别模型的评价指标主要包括 Rank-1（Rank-n）和 mAP。

（1）Rank-1（Rank-n）

假设我们输入查询的图片集为 query，待查询的图片集为 gallery，Rank-1 指的是经过行人重识别模型计算后，对 gallery 中的图片根据与 query 的相似度进行排序，其中第一张图片标签与 query 中对应的图片标签一致的数量与总 query 图片数量的比例。同理 Rank-n 则是排序后的 gallery 中的前 n 张图片标签集合中是否含有 query 中对应图片标签情况的数量与 query 图片数量的比例。Rank-n 公式如下，其中 $M(l_q, L_i^q)$ 表示对于图片 q 查询返回的前 i 张图片标签集合 L_i^q 是否包含图片 q 的标签 l_q。Q 为全体查询图片的集合。

$$M(l_q, L_i^q) = \begin{cases} 1 & if \quad l_q \in L_i^q \\ 0 & if \quad l_q \notin L_i^q \end{cases} \tag{3-3}$$

$$\text{Rank-}n=\frac{1}{\|Q\|}\sum_{q\in Q}M(l_q,L_n^q) \tag{3-4}$$

（2）mAP

P：精度，对于一张 query 图片，计算前 k 个返回结果中与 query 图片的标签相同的图片数量的比例。AP：平均精度，对于前 n 个返回结果，只对结果正确的计算精度，将所有精度求平均。mAP：对所有的 query 图片，对其所有的 AP 求平均。具体的 mAP 公式如下，其中 $N(l_q,l_i^q)$ 表示对于图片 q 查询返回的第 i 张图片的标签是否与图片 q 的标签一致。

$$N(l_q,l_i^q)=\begin{cases}1 & if \quad l_q=l_i^q\\ 0 & if \quad l_q\neq l_i^q\end{cases} \tag{3-5}$$

$$\text{m}AP=\frac{1}{\|Q\|}\sum_{q\in Q}\sum_{k=1}^{n}\frac{M(l_q,l_k^q)}{kn_q}\sum_{i=1}^{k}M(l_q,l_k^q) \tag{3-6}$$

3.3.4 消融实验

为了验证本文中关于行人重识别模型设计的有效性，针对是否使用 Id Loss 以及 TriHard Loss 进行验证。所有模型使用的训练参数均一致。Epoch 为 150，Batch Size 为 64，lr 为 0.01，优化器为 SGD。消融实验结果如表 3-1 所示：

表 3-1　行人重识别算法消融实验

序号	方法	mAP	Rank-1	Rank-5	Rank-10	Rank-20
1	PCB+Id	66.9	85.9	94.4	96.4	97.7
2	PCB+TriHard	64.3	83.7	94.2	96.3	97.6
3	PCB+Id&TriHard	75.5	90.3	96.4	97.6	98.6

根据表中数据，对使用不同损失函数的模型进行评估和比较。在 mAP 方面，使用 Id Loss 与 TriHard Loss 的模型具有最优的性能，达到了 75.5%，其他两种仅达到了 66.9%和 64.3%。

在 Rank-n 方面，同样是使用 Id Loss 与 TriHard Loss 的模型最优的效果，相对于其他两种，在 Rank-1 和 Rank-5 具有明显的提升，分别达到了 90.3%和 96.4%，在 Rank-10 和 Rank-20 虽然性能较好，但是提升并不算太明显，大约在一个百分点附近。

综上所述，根据消融实验分析的结果，在基于 PCBNet 的基础上进行改进的行人重识别模型，也就是使用 Id Loss 与 TriHard Loss 的模型相对于其他两种方法，在 mAP 和 Rank-1 方面均取得了提升。

3.3.5 实验结果

为了验证本文中提出的行人检测模型方法，将本文方法与其他行人重识别方法进行了对比[28]，数据集均为 Market1501。对比实验结果如表 3-2 所示：

表 3-2　行人重识别算法对比实验

序号	方法	mAP	Rank-1
1	SPReID[29]	71	84.4
2	APR[30]	66.9	87.0
3	SVDNet[31]	62.1	82.3
4	PCB+Id&TriHard	75.5	90.3

通过与其他模型进行对比，可以得到，本文使用的行人重识别方法，在 mAP 和 Rank-1 上均有较好的效果。并且根据各种性能分析，该模型能够较好地完成行人重识别任务，能够实现行人重识别功能。

3.4 本章小结

本章提出了一种基于 PCBNet 的改进行人重识别网络模型，通过 PCBNet 的思想将特征图划分为六个区域后，分别进行特征向量的提取，丰富行人特征粒度，并且使用 TriHard Loss 和 Id Loss 作为协同损失函数，相对于使用单个损失函数时，模型的性能得到了有效提升。

4 行人重识别系统的设计与实现

4.1 引言

随着深度学习和人工智能的不断发展，如何将智能化应用到实际生活中来提高效率愈加重要。在计算机视觉领域，行人检测和行人重识别对智能安防、智能视频监控等具有重要意义。

前两章分别介绍了本文行人检测模型的设计和行人重识别模型的设计。本章将介绍设计一个行人重识别系统，提供行人检测和行人重识别功能。该系统的主要运行逻辑如下：对于行人检测功能，系统接收来自用户提交的待检测图片或视频，系统调用行人检测模型对该图片或者视频进行检测，并将结果可视化返回给用户。对于行人重识别功能，系统接收来自用户提交的检索行人图片和待识别图片或视频，系统首先对待识别图片或视频进行行人检测得到行人位置，之后根据行人位置进行剪切得到行人图片，再将得到的行人图片和检索行人图片输入到行人重识别模型中，最后将得到的模型输出结果可视化展示给用户。

4.2 需求分析

4.2.1 功能性需求分析

在系统功能方面，整个系统不仅需要实现重识别效果，还要满足用户的基本需求，方便用户使用以及查看结果。

行人检测功能：通过用户输入的行人图片或者视频，能够实现对图片或者视频中的行人进行检测，并且进行结果展示。

行人重识别功能：能够对用户输入的查询图片以及视频进行行人重识别处理，判断行人间的相似度，并且对结果进行展示。

4.2.2 非功能性需求分析

非功能性需求则是保证系统整体流畅度，保证系统运行的需求，主要有以下几个方面。

正确性：保证系统整体运行时逻辑处理以及计算的正确性。

鲁棒性：保证系统在出现错误或者是用户错误操作引起的崩溃时，能够进行处理并进行提醒。

及时性：对于视频实时处理需要系统拥有较好的性能，使得系统在运行期间流畅。

兼容性：能够在 Windows 10 及其以上系统进行运行。

4.3 系统开发环境

本系统开发的环境配置如表 4-1 所示：

表 4-1 开发环境配置

参数	数值
开发语言	Python3.8
处理器	Intel(R) Core(TM) i7-10750H CPU @ 2.60GHz
内存	16.0 GB
系统环境	64 位 Windows 10

4.4 系统功能综述

本系统采用 PyQt5 以及 QFluent 进行设计，系统主要由用户层，业务层，数据层组成。整体系统架构如图 4-1 所示：

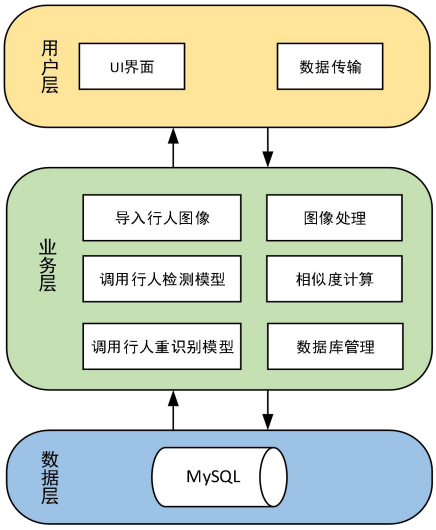

图 4-1 系统整体架构

用户层包括各种 UI 界面，主要负责与用户的交互，实现对用户各种操作的接收。业务层主要是接收来自用户层传入的图片或者视频，实现对行人检测模型

和重识别模型的调用，进行图片以及视频的重识别功能等，并将结果返回给用户层用于交互。数据层则是通过调用 MySQL 数据库进行储存和查询用户的账户信息。系统的具体流程图如图 4-2 所示：

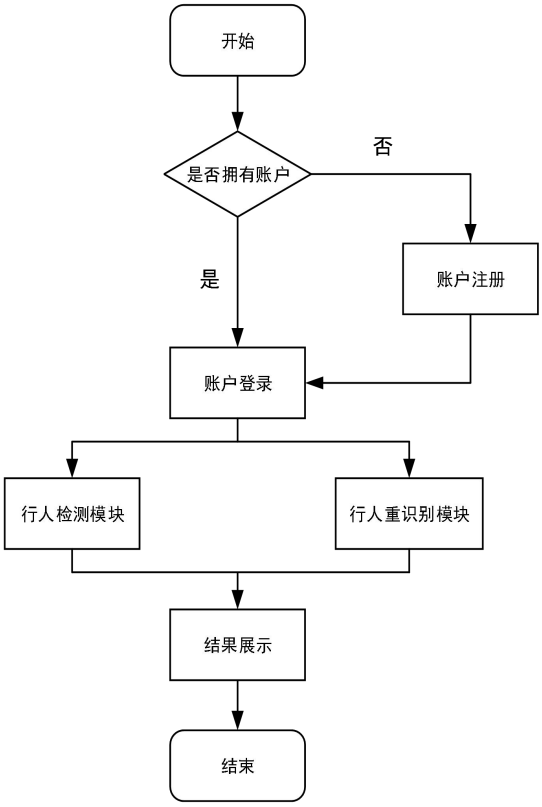

图 4-2 系统整体流程

4.4.1 用户层

用户层主要由 PyQt5 进行设计，通过 QFluent 来实现整体系统的美化功能。下面将简单介绍部分界面。

（1）行人视频检测界面

与行人图片检测界面功能类似，但是此界面支持对于视频中行人的实时检测，用户需要输入待检测视频，即可进行对于该视频中的行人进行实时检测，然后实现检测结果展示及视频播放功能。

（2）行人视频重识别界面

与行人图片重识别界面类似，在此界面，用户可以输入待查找行人图片以及待重识别视频，实现逐帧对待重识别视频进行重识别操作，并且实现视频播放相关操作功能。

（3）设置界面

在设置界面可以实现对行人检测模型和重识别模型的选择，不同的模型对应不同的性能以及计算量和参数量，用户可以根据配置进行选择。在设置界面也可以进行一些基础的设置，比如结果文件的储存路径，视频播放功能的快进和后退的长度等。

4.4.2 业务层

业务层以 Python 进行编写，主要进行处理行人检测和行人重识别功能。

行人检测和行人重识别功能主要流程则是通过获取用户层中用户输入的图片或者视频，通过调用相关模型，获取模型输出再返回给用户层。以图片重识别举例：业务层会先获取用户层输入的待查找行人图片和待重识别图片，系统首先会调用行人检测模型对待重识别图片进行处理，得出待重识别图片中的所有行人位置，之后将待重识别图片中的所有行人裁剪，调用重识别模型与待查找行人进行对比，从而在待重识别图片中查找到目标行人。

4.4.3 数据层

本系统采用 MySQL 进行相关数据的储存和访问。在数据层中，系统会接收到业务层的访问，在账户登录时，会进入数据库查找用户信息，在账户注册时，会将用户信息储存进数据库。

用户信息表的主要字段包括：id，账号，密码。如下表 4-2 所示：

表 4-2　用户信息表

列名	数据类型	长度	允许空	是否主键	说明
id	int	11	否	是	用户 id
账号	varchar	255	否	是	用户名
密码	varchar	255	否	否	用户密码

4.5 系统效果展示

在本节中，将会对本系统进行部分相关效果展示。

（1）行人视频检测界面

进入主界面后，可以通过其他界面的左侧应用栏选择进入行人视频检测界面。

在行人视频检测界面中，主要分为左半部分和右半部分，首先对左半部分进行介绍，左半部分上方用来展示原视频，下方则是用来设置相关参数，主要为行人检测结果后处理 NMS 算法的置信度参数和 IOU 阈值。并且可以自行选择是否保存检测结果，右半部分则是展示行人检测后的视频。将待检测视频导入后，点击开始检测即可进行检测。具体效果如下图所示。

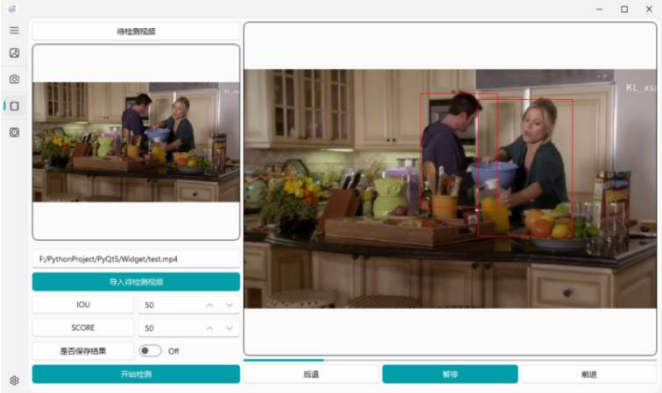

图 4-3 行人视频检测界面

（2）行人视频重识别界面

行人视频重识别界面与行人视频检测界面类似，主要是差别是左半部分不再展示原视频而是展示查询图片。导入查询图片和待识别视频后即可进行重识别操作。

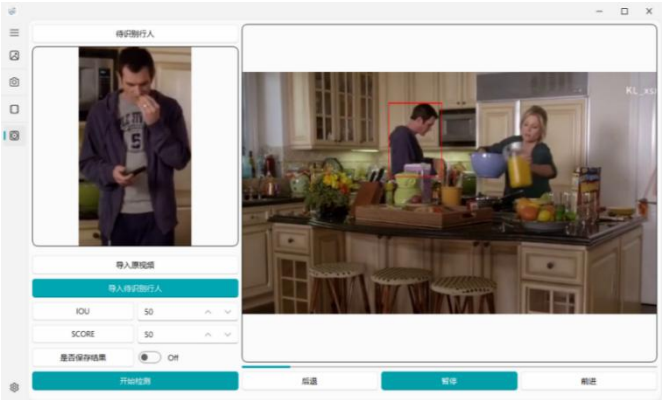

图 4-4 行人视频重识别界面

（3）设置界面

设置界面则可以进行一些基本功能的设置，比如结果保存路径，模型的选择等。本系统不仅提供本文中设计的相关模型，也提供一些其他模型方法，并且设置界面也提供一些关于本系统的一些基本介绍。

图 4-5 设置界面

4.6 本章小结

本章主要介绍了设计一个行人重识别系统且对系统的各个功能进行了详细介绍，之后又详细对系统的 UI 界面的设计进行了详细讲解，最后对系统进行了整体功能的演示。

5 总结与展望

5.1 总结

近年来，随着我国的不断发展和人民生活水平的提高，社会公共安全逐渐受到重视，视频监控作为守护国民安全的重要工具，被广泛应用于各个行业。但对于监控视频的处理却需要投入大量人力并且效率低下，如何对监控视频进行高效地处理是急需解决的问题。本文结合当前视频监控遇到的问题，对计算机视觉领域中的两个重要方面：行人检测和行人重识别技术进行了研究。行人检测在交通领域具有重要作用，能有效地对路况上的行人进行监管，行人重识别技术则可以在不同摄像头角度下去识别特定行人。针对行人检测和行人重识别技术，本文主要工作内容如下：

（1）设计了一个基于 YOLOv8 算法的改进行人检测网络，通过对 YOLOv8n 的 Backbone 以及 Head 模块中添加通道注意力机制，在参数量和计算量小幅度增长的情况下，实现了在本文数据集上的性能提升。

（2）设计了一个基于 PCBNet 改进的行人重识别网络，采用 ResNet50 网络作为特征提取网络，基于 PCBNet 的思想，将得到的特征图分为六个部分并且分别进行计算，采用 TriHard Loss 和 Id Loss 作为协同损失函数。经过实验，在 Market1501 数据集上取得了较好的效果。

（3）基于上述行人检测算法和行人重识别算法设计了行人重识别系统，该系统包含行人检测功能，行人重识别功能，并且兼容视频处理，经过测试，该系统能够较好地应用于实际场景。

5.2 展望

随着国家对安防事业的不断重视，行人检测和行人重识别技术也在这种环境下不断发展，虽然当前行人检测和行人重识别已经取得了优异的性能，但在许多方面仍然存在困难，主要有以下几个方面：

首先在行人检测和行人重识别的模型训练上，主流的方法为有监督学习，因此这也需要大量的标注数据，在某些特定场景下，由于数据缺失，会导致模型难

以进行训练。未来可以进行半监督学习和非监督学习方向的研究，减少对标注数据的需求。

其次是模型的轻量化，在进行实时行人重识别时，尤其是部署到移动端时，对模型的性能具有极高的要求，目前主流的行人重识别算法中，仍然需要较高的计算量，因此，降低参数量，减少计算量，调整和优化行人重识别模型仍然是比较重要的方向。

最后是跨模态的行人重识别，目前主流的行人重识别是基于可见光图像和视频，但是在现实生活中，数据可能以各种形式出现，比如红外光和文本描述等，在缺少可见光图像可视频时，其他模态往往能提供更多信息。

参考文献

[1] 张敏,余增,韩云星,等.面向复杂场景的行人重识别综述[J].计算机科学,2022,49(10):138-150.

[2] 黄业文,许智聪,单纯.基于深度学习的行人重识别综述[J].广州大学学报(自然科学版),2022,21(02):30-41.

[3] 王素玉,肖塞.行人重识别研究综述[J].北京工业大学学报,2022,48(10):1100-1112.

[4] 景叶怡然,余增,时云潇,等.基于伪标签的无监督领域自适应行人重识别研究综述[J].计算机科学,2024,51(01):72-83.

[5] 杨磊.基于深度学习的行人重识别综述[J].中国水运(下半月),2023,23(07):57-59.

[6] 葛亚鸣.改进表征学习和度量学习的行人再识别算法研究[D].南京邮电大学,2019.DOI:10.27251/d.cnki.gnjdc.2019.000596.

[7] Schroff F, Kalenichenko D, Philbin J. Facenet: A unified embedding for face recognition and clustering[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 815-823.

[8] Sun Y, Zheng L, Yang Y, et al. Beyond part models: Person retrieval with refined part pooling (and a strong convolutional baseline)[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 480-496.

[9] Jocher G, Chaurasia A, Qiu J. Ultralytics YOLO (Version 8.0.0) [Computer software]. https://github.com/ultralytics/ultralytics.

[10] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.

[11] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.

[12] Xiao Q, Luo H, Zhang C. Margin sample mining loss: A deep learning based method for person re-identification[J]. arXiv preprint arXiv:1710.00478, 2017.

[13] 陈扬.行人重识别技术及其在智能安防中的应用研究[D].苏州科技大学,2020.DOI:10.27748/d.cnki.gszkj.2020.000268.

[14] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.

[15] Redmon J, Farhadi A. YOLO9000: better, faster, stronger[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 7263-7271.

[16] Redmon J, Farhadi A. Yolov3: An incremental improvement[J]. arXiv preprint

arXiv:1804.02767, 2018.

[17] Bochkovskiy A, Wang C Y, Liao H Y M. Yolov4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.

[18] Jocher G. Ultralytics YOLOv5 (Version 7.0) [CP]. https://github.com/ultralytics/yolov5.

[19] Li C, Li L, Jiang H, et al. YOLOv6: A single-stage object detection framework for industrial applications[J]. arXiv preprint arXiv:2209.02976, 2022.

[20] Wang C Y, Bochkovskiy A, Liao H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 7464-7475.

[21] Zhu J Y, Park T, Isola P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2223-2232.

[22] Wang C Y, Liao H Y M, Wu Y H, et al. CSPNet: A new backbone that can enhance learning capability of CNN[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops. 2020: 390-391.

[23] He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 37(9): 1904-1916.

[24] Yang J, Fu X, Hu Y, et al. PanNet: A deep network architecture for pan-sharpening[C]//Proceedings of the IEEE international conference on computer vision. 2017: 5449-5457.

[25] Lin T Y, Maire M, Belongie S, et al. Microsoft coco: Common objects in context[C]//Computer Vision–ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part V 13. Springer International Publishing, 2014: 740-755.

[26] Redmon J, Farhadi A. Yolov3: An incremental improvement[J]. arXiv preprint arXiv:1804.02767, 2018.

[27] Zheng L, Shen L, Tian L, et al. Person re-identification meets image search[J]. arXiv preprint arXiv:1502.02171, 2015.

[28] 王继民.基于深度学习的行人检测和行人重识别研究与应用[D].山东建筑大学,2023.DOI:10.27273/d.cnki.gsajc.2023.000682.

[29] Kalayeh M M, Basaran E, Gökmen M, et al. Human semantic parsing for person re-identification[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 1062-1071.

[30] Wang J, Zhu X, Gong S, et al. Attribute recognition by joint recurrent learning of context and correlation[C]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 531-540.

[31] Sun Y, Zheng L, Deng W, et al. Svdnet for pedestrian retrieval[C]//Proceedings of the IEEE

international conference on computer vision. 2017: 3800-3808.

致　谢

不经意间已悄然步入五月，本科生涯自此也已接近尾声，回望这段旅程，充满挑战也充满收获。此刻，借此论文致谢之机，表达我对指导老师以及同学和家人的感激之情。

首先我要向我的指导老师——李莉老师表达敬意和感谢。在撰写毕业论文期间，是李莉老师经常给予我相关知识的指导，让我了解正确的方向，能够不断解决设计过程中遇到的问题。在整体毕业设计的进度把控上，李莉老师也会严格监管每周的任务完成情况，保证毕业设计的进度有序推进。并且也在我毕业设计的实现上，提出相应的修改意见，使得我的毕业设计能够更加全面和完善。在论文的撰写上，李莉老师也会指出我在文中的各种小问题，包括各种语法，错别字，文章结构等问题，坚持更正每一处细节。可以说，没有李莉老师的细心指导，就没有我这篇论文的顺利完成。

其次，也感谢学院的老师和同学们。在课堂上，老师不仅传授给了我基本的专业知识，也是老师们的言传身教，让我学会了如何做事做人，受益匪浅。是同学们的陪伴与帮助，让我的大学生活充满了欢乐与温暖，这些美好的回忆都将成为我一生的财富。

最后，特别感谢我的家人。是他们无条件的爱与支持不断支撑着我，在我遇到挫折时，是他们在不断的安慰和鼓励我，让我重拾信心，是他们默默的关怀让我内心感到温馨，言语之情已无法传达我的所思所想，我会将这份深情厚爱转化为前进的动力，不负所望。

我将会牢记这段难忘的求学之路，在挫折中不断学习，在困难中不断前进，我将会带着大学里学习的一切，继续勇敢的追逐梦想，不断前进。